



МОСКОВСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ ИМЕНИ М. В. ЛОМОНОСОВА
ФАКУЛЬТЕТ ВЫЧИСЛИТЕЛЬНОЙ МАТЕМАТИКИ И КИБЕРНЕТИКИ
КАФЕДРА ВЫЧИСЛИТЕЛЬНЫХ ТЕХНОЛОГИЙ И МОДЕЛИРОВАНИЯ

Курбацкий Вячеслав Константинович
Итерационные методы для оценки важности узлов и слоев многомерных графов

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Научный руководитель:
доцент, к.ф.-м.н.
Матвеев Сергей Александрович

Оглавление

Введение	3
1 Мера центральности мультиоднородного отображения	6
1.1 Определения	6
1.2 Существование и единственность решения	7
1.3 Эффект телепортации	8
1.4 Влияние параметров.	9
1.5 Сравнение с другими мерами центральности	11
2 Модельный пример	13
2.1 Мера различия ранжированных списков	16
3 Разреженность	18
3.1 Представление матрицы в разреженном формате	18
3.2 Сравнение	19
4 Большой датасет с цитированием	20
5 Заключение	21
Список литературы	22

Введение

Многие связи и процессы (взаимодействия людей в соцсетях, распространения инфекций, цитирование статей и т.д.) описываются графами ([1]), в которых вершины отражают взаимодействующие объекты, а рёбра – сами взаимодействия.

Определение 1. *Графом* называется совокупность множеств (V, E) , где $V = \{1, 2, \dots, n\}$ – множество вершин, $E \subseteq V \times V$ – множество рёбер. Граф называется *неориентированным* если $\forall i, j \in V : (i, j) \in E \Leftrightarrow (j, i) \in E$ и *ориентированным* в противном случае.

Определение 2. $A \in \mathbb{R}^{n \times n}$ называется *матрицей смежности графа* $G = (V, E)$, $|V| = n$, если

$$a_{ij} = \begin{cases} w_\ell(i, j) > 0, & (i, j) \in E \\ 0, & \text{иначе} \end{cases}$$

Элемент a_{ij} называется *весом ребра* $(i, j) \in E$.

Определение 3. Множество $\mathcal{G} = \{G^{(\ell)} = (V_n, E^{(\ell)})\}_{\ell \in V_L}$, где $V_n = \{1, 2, \dots, n\}$ – множество вершин, $V_L = \{1, 2, \dots, L\}$ – множество слоев и $E^{(\ell)} \subset V_n \times V_n$ – множество ребер на слое ℓ , называется *многослойным (многомерным) графом*.

Пусть $A^{(\ell)}$ – матрица смежности графа $G^{(\ell)}$, $\ell \in V_L$. Тогда *тензором смежности* называется $\mathcal{A} = (\mathcal{A}_{ijl})$:

$$\mathcal{A}_{ijl} = A_{ij}^{(\ell)} = \begin{cases} w_\ell(i, j), & (i, j) \in E^{(\ell)} \\ 0, & \text{иначе} \end{cases}$$

где $w_\ell(i, j) > 0$ – вес ребра $(i, j) \in E$. Будем рассматривать только *ненаправленные много-слойные графы*, то есть графы $\mathcal{G}$ для которых $G^{(\ell)}$ – ненаправленный $\forall \ell \in V_L$.

Пример многослойного графа – граф, изменяющийся во времени, где каждый слой отвечает состоянию графа в определенный момент времени. Примером такой системы может являться цитирование статей или обмен письмами между пользователями ([2], [3]). Ребро $e = (A, B) \in G^{(t)} \Leftrightarrow$ статья A цитирует статью B (или пользователь A отправил письмо пользователю B) в момент времени t . Для исследования таких графов полезно иметь меру важности как отдельных, вершин, так и целых слоёв. Логично требовать выполнение следующих свойств:

1. Рейтинг вершины неотрицателен и равен нулю $\Leftrightarrow$ вершина не соединена ни с одной другой вершиной в сети.
2. Чем больше ребер у вершины, тем выше ее рейтинг.
3. Чем выше рейтинг вершины, тем выше рейтинг смежных с ней вершин.

Пусть x – собственный вектор матрицы A отвечающий собственному значению λ ([4]):

$$Ax = \lambda x \Leftrightarrow \lambda x_i = \sum_{j=1}^n a_{ij} x_j$$

Пусть A - матрица смежности графа G , $x_j \geq 0$, тогда рейтинг вершины j равный x_j удовлетворяет свойствам 1-3. Чтобы гарантировать существование собственного вектора с неотрицательными координатами нужно вспомнить следующие понятия из линейной алгебры:

Определение 4. Матрица A называется *неприводимой*, если она не может быть приведена к верхней блочно-треугольной матрице подобием при помощи матрицы перестановки, то есть:

$$PAP^{-1} \neq \begin{pmatrix} B & C \\ \Theta & D \end{pmatrix}$$

для любой матрицы перестановки P . Это утверждение эквивалентно сильной связности графа $G^{(\ell)}$, для которого A - матрица смежности.

Теорема 1 (Перрона-Фробениуса). *(некоторые утверждения) Пусть матрица $A \in \mathbb{R}^{n \times n}$ - неприводимая матрица с неотрицательными элементами. Пусть $\rho(A) = r$ - спектральный радиус. Тогда r - простое (кратности 1) собственное значение матрицы A и собственные векторы (левый и правый), отвечающие этому собственному значению, имеют положительные компоненты. Более того, они единственные собственные вектора с таким свойством. Будем называть их **векторами Перрона**.*

Мера центральности с помощью собственного вектора называется упорядочиванием по Пейджу (PageRank) [5] и записывается следующим образом:

$$PR(u) = \sum_{v \in V} \frac{PR(v)}{L(v)}$$

где $L(v)$ - количество исходящих ребер из вершины $v \in V$. В таком случае $PR = \pi$ - собственный вектор матрицы P , полученной из A нормировкой столбцов на исходящую степень вершин: $P_{ij} = \frac{A_{ij}}{\sum_{k=1}^n A_{kj}}$ - матрица вероятностей перехода из одной вершины в другую. Тогда $P\pi = \pi$. На практике часто встречаются изолированные вершины, приводящие к вырожденной матрице (из-за наличия нулевых строк), из-за чего различные итерационные алгоритмы расходятся. Для этой цели вводится эффект телепортации (damping). Рассматривается матрица

$$\tilde{P} = (1 - d)P + dE, \quad d \in (0, 1),$$

где матрица E : $E_{ij} = 1, i, j = \overline{1, n}$ - матрица из единиц. Данная модификация отражает вероятность перехода на случайную вершину с вероятностью d . Стандартный выбор $d = 0.15$. Модифицированный PageRank заключается в применении описанных выше рассуждений для матрицы $\tilde{P}$. Далее будем считать матрицу P с телепортацией по умолчанию.

PageRank применим для однослойной (стационарной) системы. Пытаясь обобщить на системы, меняющиеся во времени, можно выбрать несколько подходов. В каждый отсчет времени t строить матрицу P_t и вычислять PageRank (теряется связь между слоями), либо предварительно объединить все слои в одну матрицу. Кроме того, можно рассматривать модель изменяющейся телепортации ([6], [7]) – эффект телепортации не постоянен со временем, а зависит от t . Но в таких моделях граф остается постоянным, изменение во времени происходит только за счет "внешних" источников.

Для совокупного ранжирования (не отдельно по временным слоям, а по результатам всего процесса) можно использовать следующие подходы:

Пусть A^ℓ удовлетворяет теореме при $\ell \in V_L$ и q_ℓ - вектор Перрона этой матрицы. Тогда пусть $Q = [q_1, \dots, q_L] \in \mathbb{R}^{n \times L}$. Рейтинг вершины будет соответствовать строке матрицы Q . Для получения рейтинга можно рассмотреть w - вектор весов каждого слоя (чем важнее слой тем выше вес), тогда величина $(Qw)_i$ - центральность вершины i . При отсутствии информации о важности слоёв кладем $w = \mathbf{1} = (1, \dots, 1)^T$ - вектор из единиц соответствующей размерности. Тогда определим меру eig_cen :

$$eig_cen(i) = (Q\mathbf{1})_i = \sum_{\ell=1}^L (q_\ell)_i, \quad i = \overline{1, n}$$

Так же можно сначала агрегировать слои, то есть рассмотреть матрицу $A_{agg}(w) = \sum_{\ell=1}^L w_\ell A^{(\ell)}$, где $w > 0$ - вектор весов (для простоты $w = \mathbf{1}$). Для полученной матрицы считаем $eig_cen(i)$, тем самым определив меру agg_eig :

$$agg_eig(i) = u_i, \quad i = \overline{1, n}$$

где u - вектор Перрона матрицы $A_{agg}(\mathbf{1}) = \sum_{\ell=1}^L A^{(\ell)}$.

Важность вершин так же можно оценивать без каких-либо предположений о свойствах матриц смежности слоёв при помощи меры agg_deg . Пусть $(A^{(\ell)}\mathbf{1})_i$ - рейтинг вершины i на слое ℓ . Для получения общего рейтинга вершины можно сложить рейтинг на каждом слое с определенным весом w (для простоты $w = \mathbf{1}$). Так же имеет смысл отнормировать рейтинги, чтобы их сумма равнялась 1. Мера agg_deg проста в реализации и не накладывает никаких ограничений на исходные графы, но она не учитывает влияние вершин друг на друга. Кроме того, никакая из выше указанных мер не позволяет оценить важность целого слоя, а только отдельной вершины в рамках слоя или во всей сети.

Целью работы является построение итерационного метода для оценки центральности как отдельных вершин, так и слоев с использованием разреженного формата хранения матриц, а также сравнение полученного метода с известными мерами центральности, обобщенными на многомерный случай.

1. Мера центральности мультиоднородного отображения

1.1. Определения

Мера центральности мультиоднородного отображения (f-eigenvector centrality) оценивает рейтинг как вершин, так и слоев, при этом не требуется никакая дополнительная информация о строении сети. В отличие от PageRank, учитывается связь между слоями (будет проиллюстрировано на тепловых картах).

Эта мера позволяет оценивать центральность вершин и слоёв при относительно слабых ограничениях на граф. Так же она сохраняет влияние вершин друг на друга и учитывает влияние вершины на слой, в котором она находится. Единственность рейтингов так же будет гарантирована при довольно слабых условиях. Будем считать, что рейтинг вершины x_i и слоя t_ℓ - компоненты уникального собственного вектора мульти-однородного отображения. Будем называть $f = (f_1, \dots, f_d) : \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_d} \rightarrow \mathbb{R}^{n_1} \times \dots \times \mathbb{R}^{n_d}$ мульти-однородной, если существуют неотрицательные Θ_{ij} :

$$f_i(x_1, \dots, \lambda x_j, \dots, x_d) = \lambda^{\Theta_{ij}} f_i(x_1, \dots, x_j, \dots, x_d)$$

Для любого $\lambda \in \mathbb{R}$, $i, j = \overline{1, d}$. Вектор x - собственный для f , если $\exists \lambda \in \mathbb{R}^d$: $f_i(x_1, \dots, x_d) = \lambda_i x_i, i = \overline{1, d}$.

Пусть $\mathcal{A} = (\mathcal{A}_{ij\ell})$ - тензор смежности. Рассмотрим следующую систему с параметрами α, β :

$$\begin{cases} \sum_{j=1}^n \sum_{\ell=1}^L \mathcal{A}_{ij\ell} x_j t_\ell = \mu(x_i)^\alpha, \\ \sum_{i=1}^n \sum_{j=1}^n \mathcal{A}_{ij\ell} x_i x_j = \lambda(t_\ell)^\beta \end{cases} \quad (1.1)$$

Из этой системы следует, что если вершина не соединена ни с какими другими (т.е. $A_{ij\ell} = 0$ для всех j, ℓ), то $x_i = 0$ и $t_\ell = 0$ если на слое нет ни одного ребра (т.е. $A_{ij\ell} = 0$ для всех i, j), что соответствует базовой интуиции. Рассмотрим множество:

$$\mathcal{P}_A^{n \times L} = \left\{ (x, t) \in \mathbb{R}_{\geq}^n \times \mathbb{R}_{\geq}^L : \begin{array}{l} x_i \sim \sum_{j,\ell} A_{ij\ell} \quad \forall i = 1, \dots, n \\ t_\ell \sim \sum_{i,j} A_{ij\ell} \quad \forall \ell = 1, \dots, L \end{array} \right\},$$

Будет показано, что данное множество содержит решение рассматриваемой системы (1.1). Для единственности решения будем искать его в нормированном множестве:

$$\mathcal{S}_A^{n \times L} = \{(x, t) \in \mathcal{P}_A^{n \times L} : \|x\|_1 = \|t\|_1 = 1\}$$

Положим $f = (f_1, f_2) : \mathbb{R}_{\geq}^n \times \mathbb{R}_{\geq}^L \rightarrow \mathbb{R}_{\geq}^n \times \mathbb{R}_{\geq}^L$, где

$$(f_1(x, t))_i = \left(\sum_{j=1}^n \sum_{\ell=1}^L \mathcal{A}_{ij\ell} x_j t_\ell \right)^{\frac{1}{\alpha}}, \quad (f_2(x, t))_\ell = \left(\sum_{i=1}^n \sum_{j=1}^n \mathcal{A}_{ij\ell} x_i x_j \right)^{\frac{1}{\beta}}$$

Введём так же нормированный вариант $g : \mathcal{S}_A^{n \times L} \rightarrow \mathcal{S}_A^{n \times L}$, где

$$g(x, t) = \left(\frac{f_1(x, t)}{\|f_1(x, t)\|_1}, \frac{f_2(x, t)}{\|f_2(x, t)\|_1} \right)$$

Легко видеть, что (x^*, t^*) - решение системы (1.1) $\Leftrightarrow (x^*, t^*)$ - неподвижная точка для отображения g . Дальнейший анализ сводится к доказательству сжимаемости отображения и применения теоремы о неподвижной точке сжимающего отображения.

1.2. Существование и единственность решения

Теорема 1.1. Пусть $\mathcal{A} \in \mathbb{R}_{\geq}^{n \times n \times L}$ - ненулевой тензор с неотрицательными элементами и $\alpha, \beta > 0 : 2/\beta < (\alpha - 1)$. Тогда система (1.1) имеет единственное неотрицательное решение $(x^*, t^*) \in \mathcal{S}_{\mathcal{A}}^{n \times L}$.

Доказательство. Докажем с помощью теоремы о неподвижной точке у сжимающего отображения. Пусть $\mathcal{I}$ - множество индексов и $P_{\mathcal{I}} = \{x : x_i > 0, i \in \mathcal{I}, x_i = 0, i \notin \mathcal{I}\}$. Введём метрику на $P_{\mathcal{I}}$:

$$d_{\mathcal{I}}(x, u) = \ln(\max_{i \in \mathcal{I}} \frac{x_i}{u_i} \max_{j \in \mathcal{I}} \frac{u_j}{x_j})$$

Тогда $(\{x \in P_{\mathcal{I}} : \|x\|_1 = 1\}, d_{\mathcal{I}})$ - полное метрическое пространство. Возьмём $\mathcal{I} \subseteq \{1, \dots, n\}$ и $\mathcal{J} \subseteq \{1, \dots, L\}$ так, чтобы $\mathcal{P}_{\mathcal{A}}^{n \times L} = P_{\mathcal{I}} \times P_{\mathcal{J}}$. Тензор ненулевой, поэтому $\mathcal{I}, \mathcal{J} \neq \emptyset$. Тогда для любого $b = (b_1, b_2) \in \mathbb{R}_{>}^2$ отображение

$$\delta_b((x, t), (u, v)) := b_1 d_{\mathcal{I}}(x, u) + b_2 d_{\mathcal{J}}(t, v).$$

является метрикой и тогда $(\mathcal{S}_{\mathcal{A}}^{n \times L}, \delta_b)$ - полное метрическое пространство. Так же заметим, что $\forall (x, t) \in \mathcal{S}_{\mathcal{A}}^{n \times L}, c, \tilde{c} > 0 :$

$$f_j(cx, \tilde{c}t) = c^{\Theta_{j1}} \tilde{c}^{\Theta_{j2}} f_j(x, t), \quad j = 1, 2 \quad (1.2)$$

$$\Theta = \begin{bmatrix} \alpha^{-1} & \alpha^{-1} \\ 2\beta^{-1} & 0 \end{bmatrix} \quad (1.3)$$

Элементы $\mathcal{A}$ неотрицательны, поэтому, если $(x, t), (u, v) \in \mathcal{S}_{\mathcal{A}}^{n \times L}, (x, t) \leq (u, v)$ (поэлементное неравенство), то

$$f(x, t) \leq f(u, v) \quad (1.4)$$

Заметим также:

$$x_i = u_i \frac{x_i}{u_i} \leq u_i \max_{i \in \mathcal{I}} \frac{x_i}{u_i}$$

$$t_i = v_i \frac{t_i}{v_i} \leq v_i \max_{i \in \mathcal{J}} \frac{t_i}{v_i}$$

Тогда пользуясь (1.4) получаем:

$$f(x, t) \leq f(u \max_{i \in \mathcal{I}} \frac{x_i}{u_i}, v \max_{i \in \mathcal{J}} \frac{t_i}{v_i})$$

Пользуясь однородностью функции (1.2) получаем:

$$f_j(x, t) \leq \left(\max_{i \in \mathcal{I}} \frac{x_i}{u_i} \right)^{\Theta_{j1}} \left(\max_{i \in \mathcal{J}} \frac{t_i}{v_i} \right)^{\Theta_{j2}} f_j(u, v), \quad j = 1, 2 \quad (1.5)$$

Поменяв местами (x, t) и (u, v) получим:

$$f_j(u, v) \leq \left(\max_{i \in I} \frac{u_i}{x_i} \right)^{\Theta_{j1}} \left(\max_{i \in J} \frac{v_i}{t_i} \right)^{\Theta_{j2}} f_j(x, t), \quad j = 1, 2 \quad (1.6)$$

Из (1.5), (1.6) получаем, что для любого $b \in \mathbb{R}_{>}^2$:

$$\delta_b(f(x, t), f(u, v)) \leq \max \left\{ \frac{(\Theta^T b)_1}{b_1}, \frac{(\Theta^T b)_2}{b_2} \right\} \delta_b((x, t), (u, v))$$

Положим $\rho = \frac{\sqrt{8\alpha+\beta}+\sqrt{\beta}}{2\alpha\sqrt{\beta}}$, $b_1 = \alpha\rho$, $b_2 = 1$. Тогда $\Theta^T b = \rho b$, причём $2/\beta < (\alpha - 1)$, поэтому:

$$8\alpha + \beta = \frac{2}{\alpha - 1} 4\alpha(\alpha - 1) + \beta < \beta(4\alpha(\alpha - 1) + 1) = \beta(2\alpha - 1)^2 \Rightarrow \rho < 1$$

То есть имеем соотношение:

$$\delta_b(f(x, t), f(u, v)) \leq \rho \delta_b((x, t), (u, v)), \quad \rho < 1$$

Так же заметим, что $\delta_b((cx, \tilde{c}t), (au, \tilde{a}v)) = \delta_b((x, t), (u, v)) \quad \forall c, \tilde{c}, a, \tilde{a} > 0$.

То есть $\delta_b(g(x, t), g(u, v)) = \delta_b(f(x, t), f(u, v)) \leq \rho \delta_b((x, t), (u, v))$. Поэтому отображение является сжимающим и существует единственная неподвижная точка (x^*, t^*) . Она и будет решением для $\lambda = \|f_1(x^*, t^*)\|_1$, $\mu = \|f_2(x^*, t^*)\|_1$ и теорема доказана. $\square$

Положительность решения гарантируется двумя условиями:

- 1) $\forall \ell \in V_L \quad \exists i, j \in V_n : \mathcal{A}_{ij\ell} > 0$
- 2) $\forall i \in V_n \quad \exists \ell \in V_L, j \in V_n : \mathcal{A}_{ij\ell} > 0$

Причём первое требование всегда можно удовлетворить, предварительно убрав все пустые (неинформативные) слои. Таким образом, имеем неподвижную точку (x^*, t^*) (в дальнейшем будем обозначать просто (x, t)). Компонента x отвечает за рейтинг каждой вершины с учетом каждого слоя, компонента t отвечает за рейтинг каждого слоя, учитывая находящиеся на нем вершины. Рейтингом вершины i на слое τ будем считать величину $x[i]t[\tau]$. Заметим, что такой подход сохраняет упорядочивание независимо от слоя (т.к. в пределах каждого слоя τ рейтинги вершин домножаются на одну и ту же величину $t[\tau]$, из-за чего отношение рейтингов остается постоянным). Это говорит о том, что данный подход с мультиоднородным отображением позволяет отследить динамику изменения рейтинга вершины относительно самой вершины в разные моменты времени, но не позволяет оценивать относительные изменения рейтингов вершин.

1.3. Эффект телепортации

По аналогии с PageRank, введем эффект телепортации с тем же параметром, чтобы гарантировать положительность решения: Имеем исходные выражения:

$$(f_1(x, t))_i = \left(\sum_{j=1}^n \sum_{\ell=1}^L A_{ij\ell} x_j t_\ell \right)^{\frac{1}{\alpha}}, \quad (f_2(x, t))_\ell = \left(\sum_{i=1}^n \sum_{j=1}^n A_{ij\ell} x_i x_j \right)^{\frac{1}{\beta}}$$

$$\begin{aligned}
A_{ij\ell} &\rightarrow (1-d)A_{ij\ell} + d \Rightarrow \\
(f_1(x, t))_i &= \left(\sum_{j=1}^n \sum_{\ell=1}^L [(1-d)A_{ij\ell} + d]x_j t_\ell \right)^{\frac{1}{\alpha}} = \left((1-d) \sum_{j=1}^n \sum_{\ell=1}^L A_{ij\ell} x_j t_\ell + d \sum_{j=1}^n \sum_{\ell=1}^L x_j t_\ell \right)^{\frac{1}{\alpha}} = \\
&\sum_{j=1}^n \sum_{\ell=1}^L x_j t_\ell = \left(\sum_{j=1}^n x_j \right) \left(\sum_{\ell=1}^L t_\ell \right) \Rightarrow \\
(f_1(x, t))_i &= \left((1-d) \sum_{j=1}^n \sum_{\ell=1}^L A_{ij\ell} x_j t_\ell + d \left(\sum_{j=1}^n x_j \right) \left(\sum_{\ell=1}^L t_\ell \right) \right)^{\frac{1}{\alpha}}
\end{aligned}$$

Аналогично получается:

$$(f_2(x, t))_\ell = \left((1-d) \sum_{i=1}^n \sum_{j=1}^n A_{ij\ell} x_i x_j + d \left(\sum_{i=1}^n x_i \right)^2 \right)^{\frac{1}{\beta}}$$

Эти преобразования полезны при реальных вычислениях: реальные системы имеют большие размеры и разреженную структуру, из-за чего вычисления возможны только в разреженном (например, CSR) формате (подробнее будет рассмотрено в секции 3). С одноранговой добавкой разреженность теряется (матрицы становятся плотными). Выведенные тождества помогают учитывать добавку независимо от разреженной части.

1.4. Влияние параметров.

Теорема о неподвижной точке требует только $\alpha, \beta > 0$ and $2/\beta < (\alpha - 1)$. Так же можно получить следующую оценку $\forall \varepsilon > 0$ и для всех k :

$$k \geq \frac{\ln((1-\rho)\varepsilon) - \ln(C)}{\ln(\rho)}$$

справедлива оценка $\|(x^{(k)}, t^{(k)}) - (x^*, t^*)\|_\infty \leq \varepsilon$

где $\rho = \frac{\sqrt{8\alpha+\beta} + \sqrt{\beta}}{2\alpha\sqrt{\beta}}$ и C :

$$C = \rho \ln \left(\max_{i, i' \in I} \frac{\sum_{j=1}^n \sum_{\ell=1}^L A_{ij\ell}}{\sum_{j=1}^n \sum_{\ell=1}^L A_{ij'\ell}} \right) + \frac{1}{\beta} \ln \left(\max_{\ell, \ell' \in J} \frac{\sum_{i=1}^n \sum_{j=1}^n A_{ij\ell}}{\sum_{i=1}^n \sum_{j=1}^n A_{ij\ell'}} \right)$$

Вывод этой и остальных теорем о мультиоднородном отображении изложены в [8] Из этой оценки следует, что увеличение, например, параметра α при фиксированном β должно улучшать сходимость итерационного метода. Соответствующий график зависимости числа итераций k от α при фиксированном ε показан ниже.




Рис. 1. Количество итераций при различных α

Сходимость ускоряется, но наблюдается так же другой эффект: значения рейтингов всех вершин сходятся к одному значению, что показано на графике (2)




Рис. 2. Рейтинги наиболее и наименее важных вершин при различных α .

Поэтому предельный случай $\alpha \rightarrow \infty$ не представляет собой интереса, хоть и сойдется за 1 итерацию. Для определенности в дальнейшем будем использовать значения $\alpha = 2.5$, $\beta = 2$ (удовлетворяет теореме).

1.5. Сравнение с другими мерами центральности

Было замечено, что для случайных симметричных матриц с элементами из равномерного распределения все меры дают примерно одинаковые оценки - судя по всему дело в том, что при таком распределении в среднем все вершины равнозначны, поэтому все меры ставят им равные рейтинги. Поэтому в псевдослучайную матрицу были случайным образом добавлены 0 и 1, чтобы вершины уже имели не настолько близкие рейтинги. Мультиоднородное отображение отмечено на графиках как Cf .




Рис. 3. Соотношение рейтингов по разным мерам. ($n = 50, L = 2$, веса случайные)

Из графиков видно, что рассматриваемые меры центральности дают довольно сильно отличающиеся результаты. В дальнейшем будет рассмотрен не только совокупный рейтинг, но и рассмотрена динамика изменения важности вершин в течение времени.

2. Модельный пример

Рассмотрим модельный пример, иллюстрирующий различные эффекты, проявляющиеся при использовании упорядочивания по Пейджу и мультиоднородного отображения. Рассмотрим стартовый граф G_0 :




Рис. 4. Начальное состояние графа G_0 .

Размер вершин на визуализации и процент под именем вершины отражают PageRank соответствующей вершины. Для симулирования изменения по времени была рассмотрена следующая простая модель изменения графа:

В момент времени $t \in [1, T]$ происходит одно из следующих событий:

- 1) Добавление случайного (отсутствующего ранее) ребра с весом $w = 1$ с вероятностью $p_1 = 0.4$
- 2) Изменение веса случайного ребра на величину $\xi \in N(a, b)$ (в данном случае выбраны $a = 1, b = 10$) с вероятностью $p_2 = 0.4$
- 3) Удаление случайного ребра с вероятностью $p_3 = 0.2$

Данный процесс не соответствует никаким реальным системам, а только лишь иллюстрирует поведение алгоритмов на простых изменяющихся сетях. После $T = 100$ итераций граф принимает следующий вид:




Рис. 5. Конечное состояние графа G_0 .

Можно показать, как изменялись рейтинги вершин этого графа с помощью различных визуализаций. В данном случае сравниваются: мультиоднородное отображение, PageRank для каждого слоя и PageRank для результирующей системы, являющейся объединением всех слоев.




Рис. 6. Динамика изменения рейтингов.

Наблюдается отсутствие динамики на первых двух тепловых картах: изменение по времени (вдоль горизонтальной оси) либо почти незаметно, либо происходит скачками, в то время как у мультиоднородного отображения изменения более плавные и монотонные. Так же можно рассмотреть изменение рейтинга конкретной вершины с течением времени. В случае мультиоднородного отображения рейтингом вершины i в момент времени j будем считать величину $x[i]t[j]$, где (x, t) - неподвижная точка отображения f . Из-за различия шкал, (x, t) была сужена коэффициентом, чтобы графики было хорошо видно – на динамику это не влияет.




Рис. 7. Изменение рейтинга одной из вершин.

Можно заметить схожесть PageRank методов и, вообще говоря, различие с мультиоднородным отображением.

2.1. Мера различия ранжированных списков

Имеет смысл так же сравнить, как отличается "топ вершин" у PageRank и мультиоднородного отображения по результатам изменений графа. Для этого используется мера intersection similarity. Пусть $\mathcal{L}^1, \mathcal{L}^2$ - упорядоченные по убыванию рейтинга списки, а $\mathcal{L}_k^i$ - множество первых k элементов списка $i = 1, 2$. Тогда:

$$\text{isim}_K(\mathcal{L}^1, \mathcal{L}^2) = \frac{1}{K} \sum_{k=1}^K \frac{|\mathcal{L}_k^1 \Delta \mathcal{L}_k^2|}{2k}$$

где K возьмем равным количеству всех вершин, а Δ означает симметрическую разность множеств. Нетрудно заметить, что если $\mathcal{L}^1 = \mathcal{L}^2$, то $\mathcal{L}_k^1 = \mathcal{L}_k^2 \Rightarrow |\mathcal{L}_k^1 \Delta \mathcal{L}_k^2| = 0 \forall k = \overline{1, K} \Rightarrow \text{isim}_K(\mathcal{L}^1, \mathcal{L}^2) = 0$. Наоборот, если списки полностью различные (пересечение пустое), то $\text{isim}_K(\mathcal{L}^1, \mathcal{L}^2) = 1$. Таким образом, данная мера является мерой расстояния – чем она больше, тем сильнее различаются упорядоченные списки. Возьмем за $\mathcal{L}^1$ – топ вершин согласно f-eigenvector centrality (упорядоченный по x из (x, t)) и за $\mathcal{L}^2$ – топ вершин, полученный

усреднением рейтингов PageRank по каждому слою. Было проведено некоторое достаточно большое число экспериментов и посчитана средняя intersection similarity. В данном случае $\mathbb{E}(\text{isim}_K(\mathcal{L}^1, \mathcal{L}^2)) \approx 0.5$ – т.е. в среднем PageRank и мультиоднородное отображение заметно отличаются. Далее будет проанализирована структура матриц, чтобы обосновать использование разреженного формата хранения.

3. Разреженность

Реальные системы имеют большие размеры – количество вершин порядка 10^4 уже приводит к большим затратам на вычисления и память. Т.к. работа происходит с тензором, в качестве решения можно использовать различные тензорные разложения. В [9] предложено использовать формат тензорного поезда ([10], [11]) при предположениях о малоранговости структуры. В отличие от искусственных данных, реальные системы скорее разреженные, чем малоранговые. Это можно отметить на примере датасета [3], содержащего данные о пересылках письмами между пользователями в течение некоторого периода времени. Тензор смежности имеет размеры порядка $10^3 \times 10^3 \times 10^2$, что позволяет явно посчитать сингулярные числа матриц развертки и исследовать систему на малоранговость:




Рис. 8. Сингулярные числа матриц разверток тензора $\mathcal{A}$.

Графики сингулярных чисел матриц разверток 8 показывают, что хоть и наблюдается резкое убывание сингулярных чисел, матрицы скорее не являются малоранговыми. В то же время можно оценить разреженность тензора. Пусть $nonzero(\mathcal{A})$ и $size(\mathcal{A})$ - количество ненулевых элементов и общее число элементов тензора $\mathcal{A}$ соответственно. Тогда для данного тензора:

$$\frac{nonzero(\mathcal{A})}{size(\mathcal{A})} \approx 7 * 10^{-4}$$

что свидетельствует о разреженности тензора, поэтому использование формата является эффективным.

3.1. Представление матрицы в разреженном формате

Для эффективного использования разреженности используется compressed sparse row (CSR) формат. В данном формате хранится не вся матрица (что неэффективно из-за преобладающего числа нулевых элементов), а только информация о ненулевых элементах следующим образом: массив `data` хранит все ненулевые элементы в порядке обхода слева-направо и сверху-вниз, массив `indices` хранит номера столбцов, на которых расположены элементы из `data`, массив `indptr` в качестве элемента i хранит число ненулевых элементов до $i - 1$ строки включительно.

Пример 1.

$$A = \begin{pmatrix} 0 & 0 & 5 & 0 \\ 1 & 0 & 0 & 2 \\ 0 & 0 & 0 & 0 \\ 0 & 3 & 0 & 4 \end{pmatrix} \quad \begin{array}{l} \text{data} = [5, 1, 2, 3, 4] \\ \text{indices} = [2, 0, 3, 1, 3] \\ \text{indptr} = [0, 1, 3, 3, 5] \end{array}$$

Данный формат позволяет значительно сократить используемую память и производить быстрее матричные операции (в частности, умножение матрицы на вектор).

3.2. Сравнение

Для датасета [3] было проведено сравнение времени выполнения алгоритма в обычной и разреженной реализации:

Формат	Среднее время итерации (с)	Общее время (с)
Плотный	1.62	40.45
CSR	$1.8 \cdot 10^{-2}$	0.48

что демонстрирует сильное ускорение даже на относительно небольшом датасете содержащем $\approx 10^3$ вершин.

4. Большой датасет с цитированием

Данный датасет содержит $\approx 3 \cdot 10^4$ вершин, которые изменяются в пределах $\approx 10^2$ временных слоев. Матрица каждого слоя хранится в разреженном формате.




Рис. 9. Динамика изменения рейтингов.

Первая тепловая карта демонстрирует динамику изменения рейтингов, аналогичную рассмотренной в модельном примере. Вторая тепловая карта построена путем применения отображения не ко всему тензору, а к каждому слою отдельно (по аналогии с PageRank). Видно, что в первом случае присутствует выраженная временная зависимость рейтингов, что не наблюдается на втором графике. Ниже приведено сравнение времени выполнения для мультиоднородного отображения и упорядочивания по Пейджу.

Алгоритм	Общее время (с)
Cf	7.04
PageRank	11.39

5. Заключение

Было рассмотрена модель многомерного (многослойного) графа, моделирующая изменение связей в системе с течением времени. Для таких систем была рассмотрена модель мультиоднородного отображения (f-eigenvector centrality, Cf) – способ обобщить известное упорядочивание по Пейджу на многомерный случай. Были приведены теоретические обоснования сходимости, оценки скорости сходимости при разных значениях гиперпараметров α , β , изучено поведение в предельных случаях (при $\alpha \rightarrow \infty$). Полученный алгоритм был применен как к модельному примеру для иллюстрации основных различий с PageRank, так и к нескольким реальным датасетам ([2], [3]). Для датасета [3] были построены сингулярные разложения матриц развертки тензора и было показано, что реальные системы имеют скорее разреженную, чем малоранговую структуру, из-за чего использование малоранговых тензорных аппроксимаций ([9], [10], [11]) не столь эффективно, поэтому для вычислений использовался CSR формат хранения разреженных матриц. Также по сравнению с исходным итерационным методом [8] был добавлен эффект телепортации (дампинг), отражающий элемент случайности в связях и гарантирующий сходимость итерационного метода. Для эффективного использования разреженности метод простой итерации был преобразован так, чтобы отдельно вычислять отображение для разреженной матрицы и одноранговой добавки. На примере датасета [2] было показано различие применения метода для каждого слоя по отдельности и для всего тензора, также было проведено сравнение времени выполнения с PageRank, примененного к каждому слою.

Как было упомянуто, данное мультиоднородное отображение строит сепарабельные рейтинги слоев и вершин (отдельно компоненты x и t), из-за чего ранжирование остается постоянным по времени, поэтому имеет смысл в поиске иного, более гибкого метода, позволяющего лучше оценивать поведение системы. Так же, возможно, стоит ввести изменяющуюся во времени телепортацию, как в ([6], [7]), чтобы учитывать не только внутренние изменения, но и внешние тренды. Кроме того, для оптимизации можно реализовывать параллельные вычисления (итерации представляют из собой умножения матриц на вектор), либо использовать арифметику пониженной точности.

Исходный код, а так же jupyter-ноутбук со всем изложенным можно найти в репозитории <https://github.com/kurbatskii-vyacheslav/Centrality>.

Список литературы

1. Харари Ф. Теория графов. — Издательство Мир, 1973.
2. Leskovec J., Kleinberg J., Faloutsos C. Graphs over Time: Densification Laws, Shrinking Diameters and Possible Explanations // Proceedings of the Eleventh ACM SIGKDD International Conference on Knowledge Discovery in Data Mining. — ACM. 2005. — С. 177—187.
3. Paranjape A., Benson A. R., Leskovec J. Motifs in temporal networks // Proceedings of the Tenth ACM International Conference on Web Search and Data Mining. — 2017. — С. 601—610.
4. Тыртышников Е. Матричный анализ и линейная алгебра. — Физматлит, 2007.
5. Brin S., Page L. The anatomy of a large-scale hypertextual web search engine // Computer Networks and ISDN Systems. — 1998.
6. Rossi R. A., Gleich D. F. Dynamic PageRank using Evolving Teleportation // Algorithms and Models for the Web Graph. — 2012.
7. Gleich D. F., Rossi R. A. A Dynamical System for PageRank with Time-Dependent Teleportation // arXiv preprint. — 2024.
8. Tudisco F., Arrigo F., Gautier A. Node and layer eigenvector centralities for multiplex networks // SIAM Journal on Applied Mathematics. — 2018.
9. Shcherbakova E. M., Tudisco F., Tyrtyshnikov E. E. Fast computation of eigenvector centralities for multilayer networks with nonnegative tensor train // Lobachevskii Journal of Mathematics. — 2025.
10. Тыртышников Е. Е., Матвеев С. А. Алгебраические вычисления, тензоры и оптимизация: учебно-методическое пособие для студентов магистратуры филиала МГУ в г. Сарове. — М. : Издательство Московского университета, 2024. — Электронное издание.
11. Oseledets I. V. Tensor-train decomposition // SIAM Journal on Scientific Computing. — 2011.
12. Arrigo F., Tudisco F. Multi-dimensional, multilayer, nonlinear and dynamic HITS // Proceedings of the 2019 SIAM International Conference on Data Mining. — SIAM. 2019. — С. 369—377.
13. Cipolla S., Durastante F., Tudisco F. Nonlocal pagerank // ESAIM: Mathematical Modelling and Numerical Analysis. — 2021. — Т. 55, № 1. — С. 77—97.